ӨГӨГДЛИЙН ДҮРСЛЭЛ — Даалгавар 2–4

Хичээл: Өгөгдлийн дүрслэл | Нэр: _____ | Код: _____

Ашигласан өгөгдөл: weatherHistory.csv, retail_sales_dataset.csv, adult.csv.

Зорилго: өгөгдөл бэлтгэх, зөв график сонгох, аномали/хэв маяг тайлбарлах, хайгуул–баталгаажуулалт–мэдлэг бий болгох 3 гогцоог хэрэглэх.

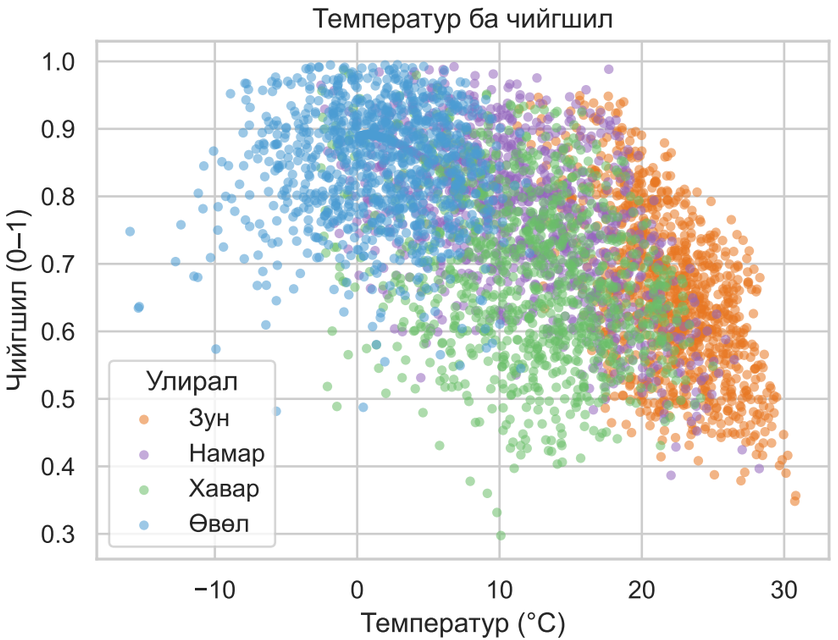
1. Өгөгдөл бэлтгэл ба Chi (2000) төлөвүүд

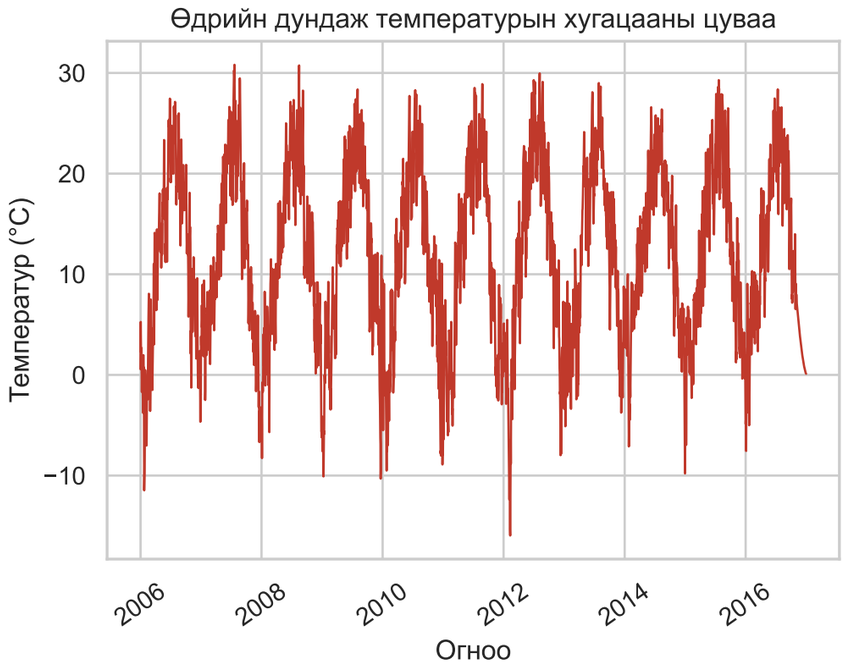
Weather History: 4,019 өдөрт агрегатлав. Температур, чийгшил, бороо орсон цагийн тоо, Summary-ийн мод утгыг ашиглав.

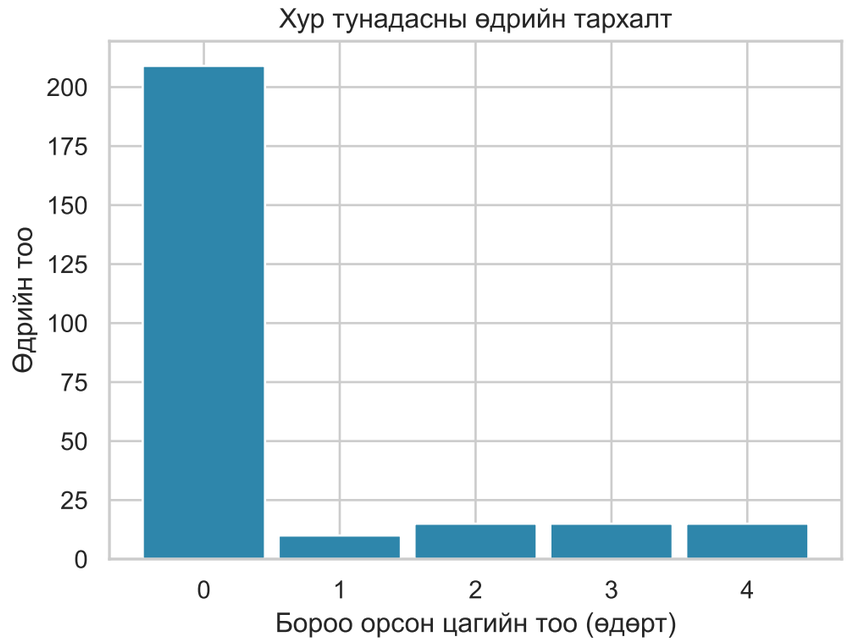
Өгөгдлийн үнэ цэнэ: түүхий CSV. Шинжилгээний ангилал: огноо ба улирлаар бүлэглэсэн өдөр тутмын хүснэгт. Дүрслэлийн ангилал: байрлал, хугацаа, тархалтыг харуулах график. Зурган өгөгдөл: эцсийн PNG/PDF график.

Анхаарах нь: эх өгөгдөлд үүлэрхэг байдлын 0–8 тоон багана байхгүй тул Summary (Clear, Partly Cloudy гэх мэт)-ийг төлөөлөл болгон хадгалсан. Энэ нь хэмжилтийн яг орлуулалт биш.

Даалгавар 2 — Weather History (өдрийн агрегат)







2. Weather — олдвор, аномали, дараагийн шинжилгээ

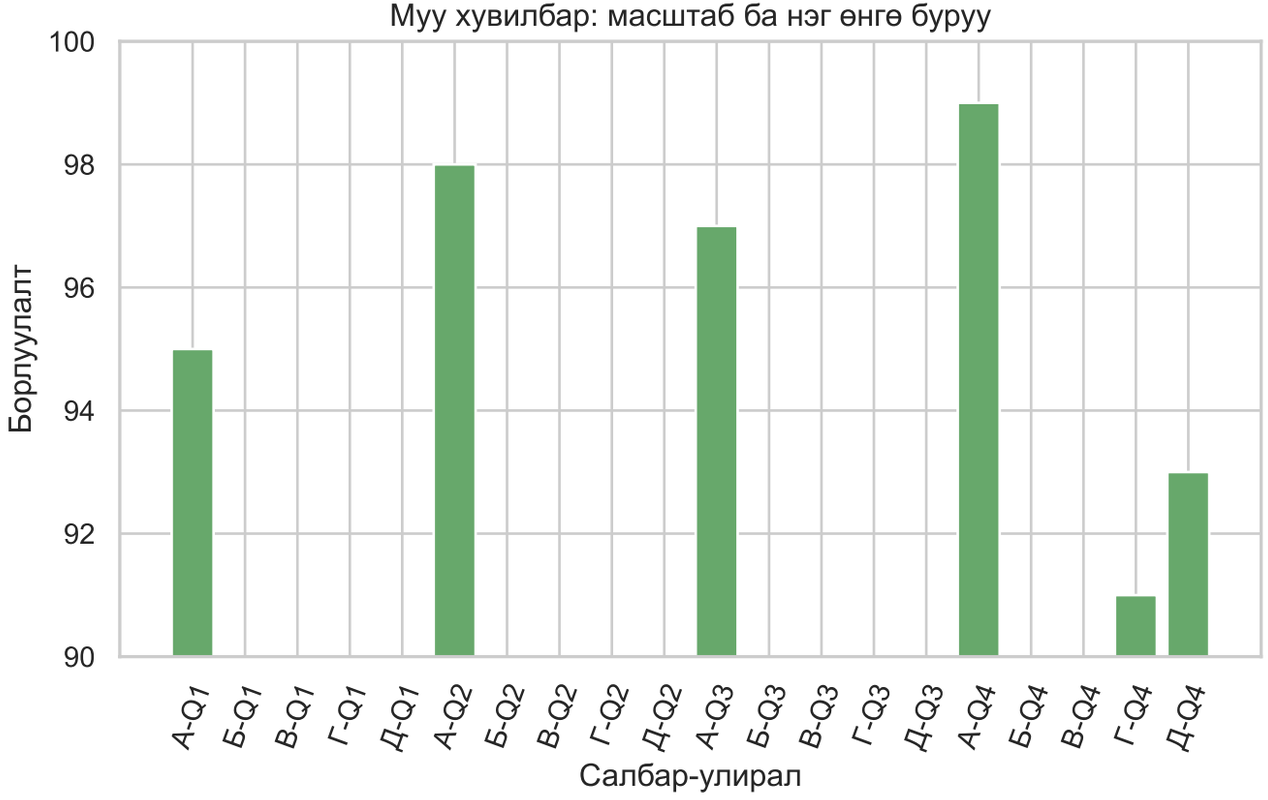
Олдвор: зун температур өндөр, чийгшил харьцангуй бага; өвөл температур бага, чийгшил өндөр байх улирлын ялгаа ажиглагдана.

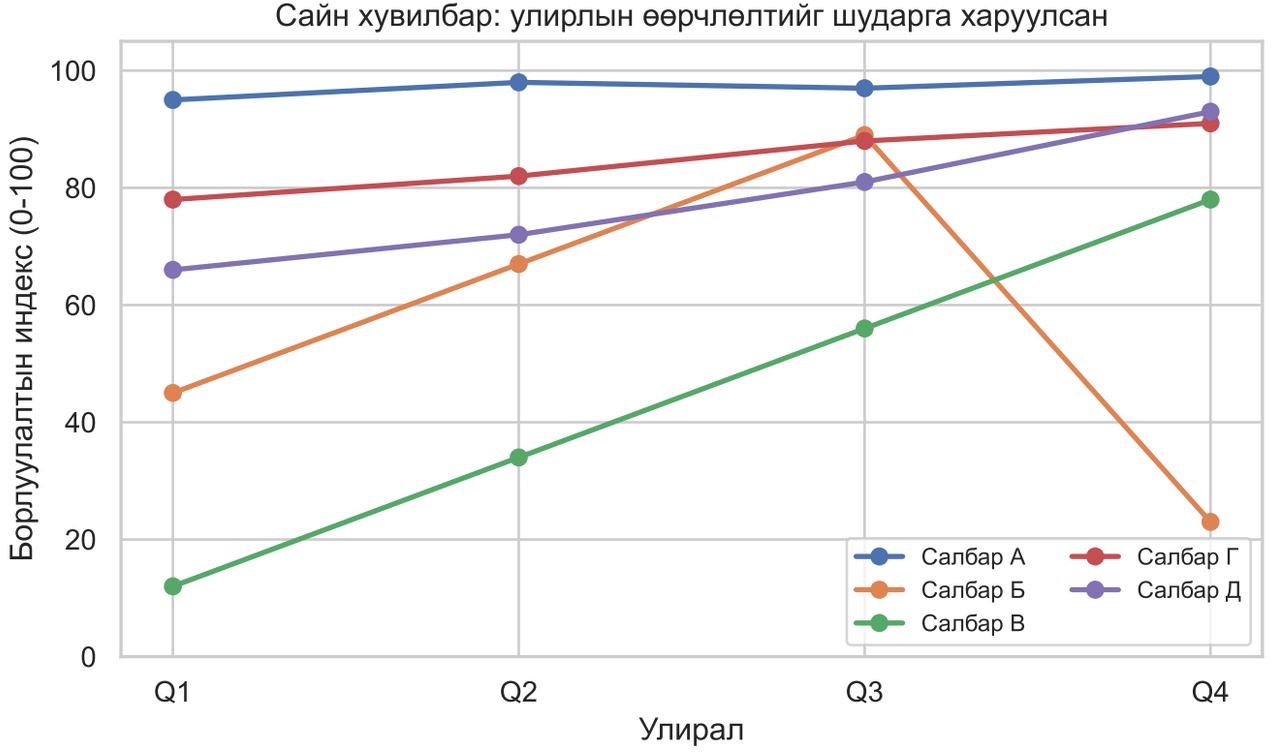
Аномали: температур огцом өөрчлөгдсөн өдөр, мөн бороо орсон цагийн тоо ердийн түвшнээс их өдөр нь шалгах цэг болно. Аномали гэж шууд шүүхгүй; эхлээд цагийн түүхий мөрүүдээр буцааж нягтална.

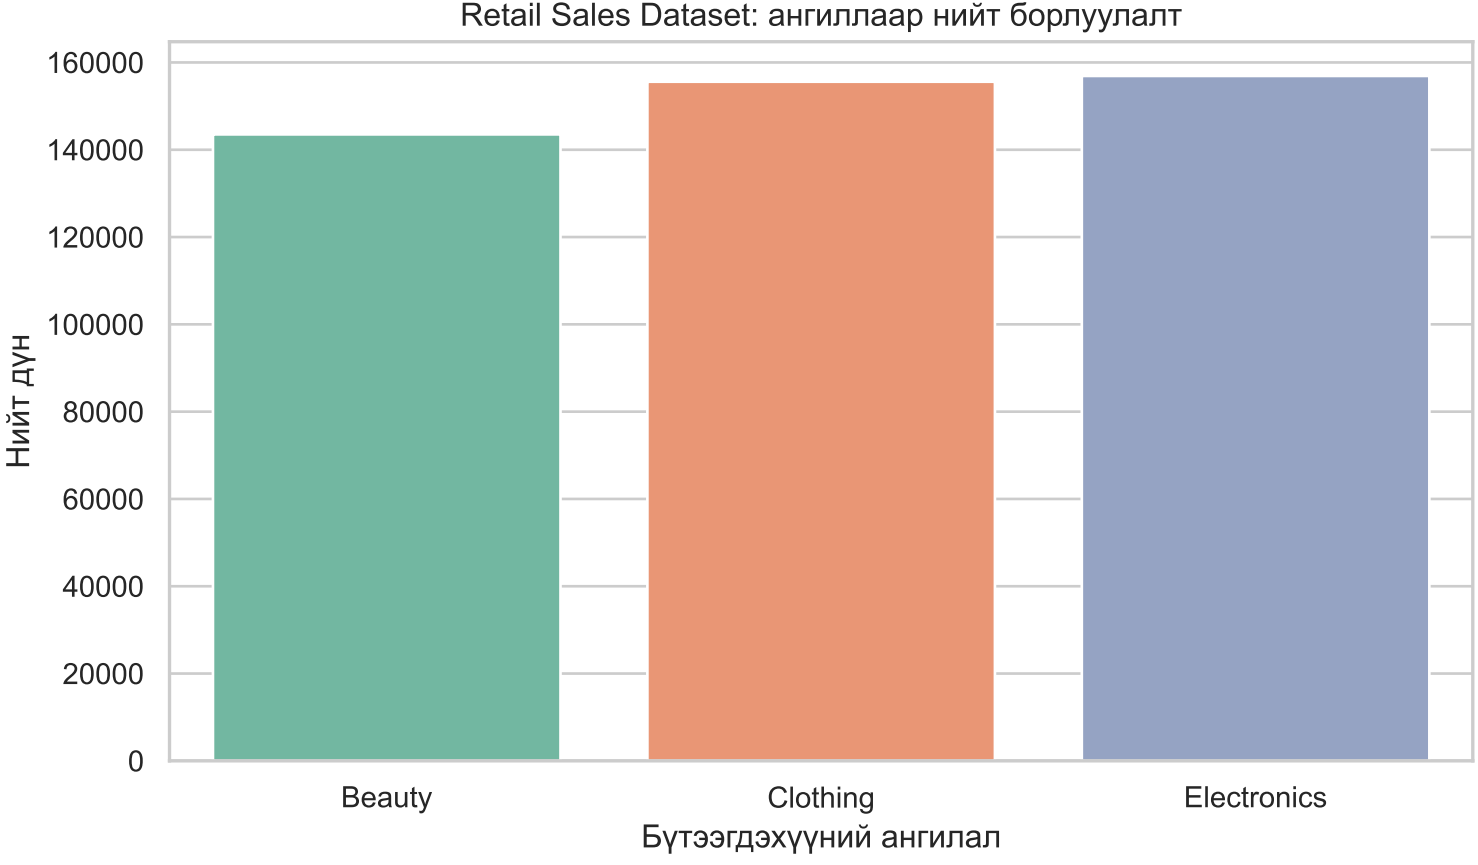
Магадгүй шалтгаан: фронтын нөлөө, шуурга, хэмжилтийн төхөөрөмж/өгөгдөл тасарсан үе. Нэмэлт арга: улирал тус бүрийн IQR/z-score, rolling mean, корреляци, Summary ангиллын хүснэгт, missing/duplicate шалгалт.

Өнгөний тайлбар: цэнхэр=өвөл, ногоон=хавар, улбар=зун, нил ягаан=намар. Өнгө нь улирлыг шууд ялгуулах pre-attentive кодлолт.

Даалгавар 3 — Дүрслэлийн шалгуурын хэрэглээ






Retail Sales Dataset: ангиллаар нийт борлуулалт
Нийт дүн
0
20000
40000
60000
80000
100000
120000
140000
160000
Beauty
Clothing
Electronics
Бүтээгдэхүүний ангилал

3. Retail — муу дүрслэлийг үнэлж сайжруулсан нь

Шударга: у тэнхлэгийг 90–100-аар тасалсан нь бага утгуудын ялгааг нууж, хэмжээний ойлголтыг гажуудуулна. Сайжруулалт: 0–105 масштаб.

Ойлгомжтой: “График” гэсэн ерөнхий гарчиг, бүгд ногоон өнгө нь ямар үзүүлэлт, аль улирал болохыг хэлэхгүй. Сайжруулалт: тодорхой гарчиг, улирал/салбарыг ялгасан тэмдэглэгээ.

Хялбар: шошго давчуу, нэг графикт олон багана байна. Сайжруулалт: улирлыг х тэнхлэгт байрлуулж, салбар бүрийг нэг шугамаар харуулсан.

Үнэ цэнэтэй: сайжруулсан график нь аль салбар өсөж/буурч байгааг шууд харуулна. Retail dataset өөрөө салбарын баганагүй тул бодит dataset-ийн Product Category борлуулалтыг тусад нь үзүүлэв.

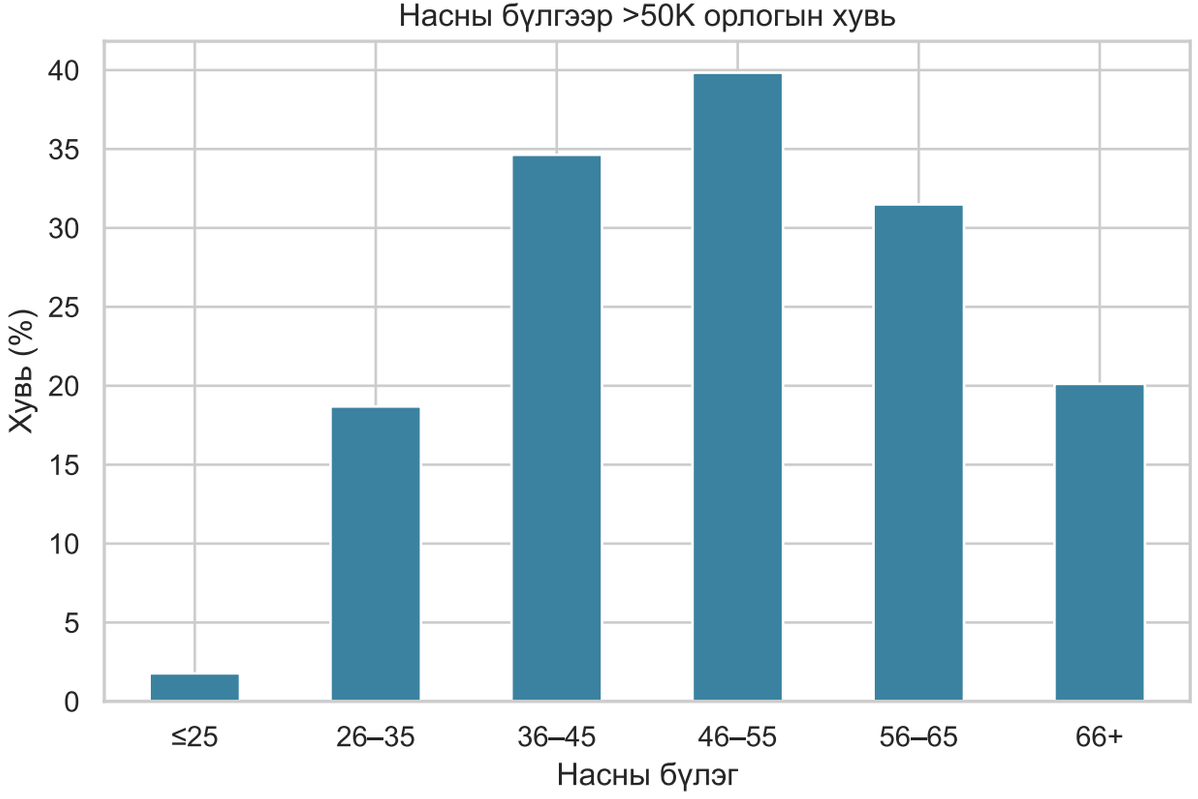
4. Adult — мэдлэг бий болгох 3 гогцоо

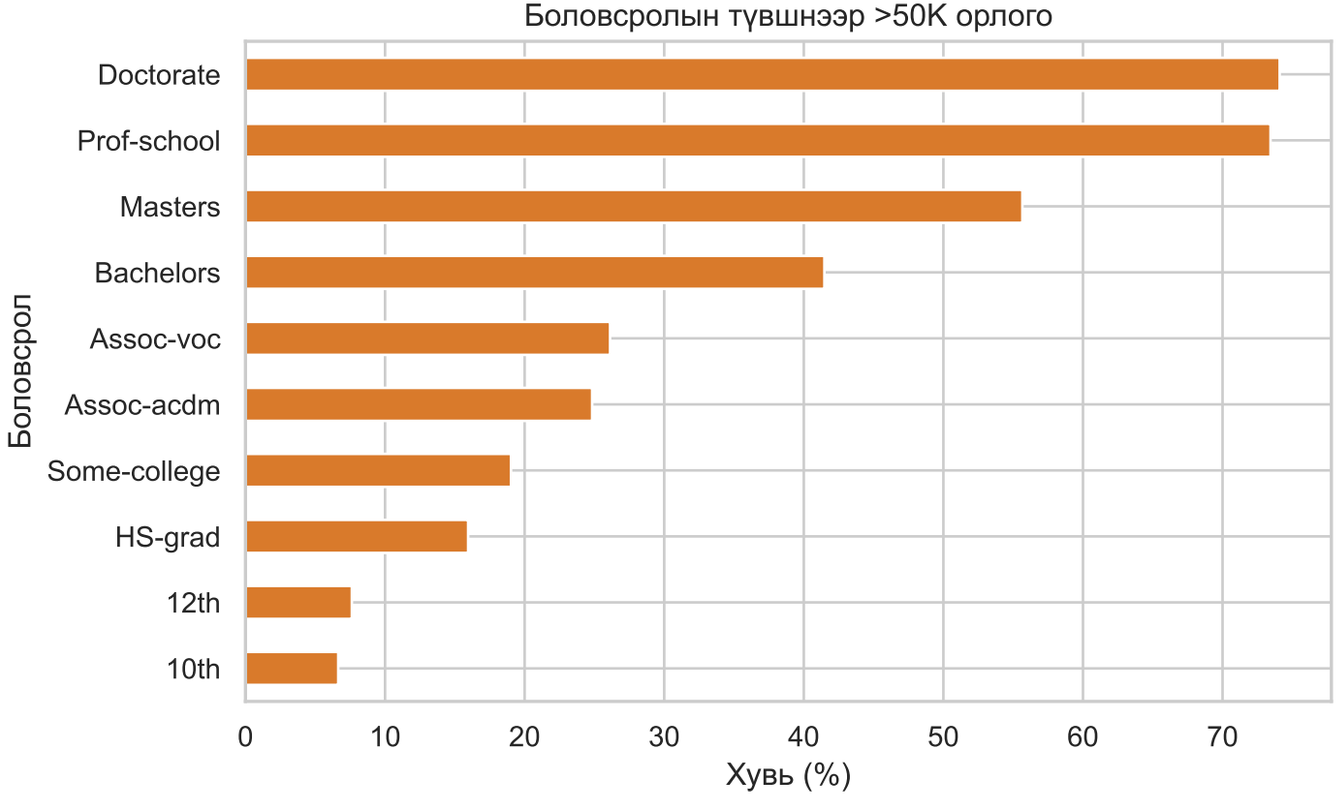
Хайгуулын гогцоо: насны бүлэг, хүйс, боловсрол, орлогын тархалтыг bar chart, histogram, boxplot, stacked bar, heatmap-аар харна. Анхны олдвор: нас/боловсролын бүлгүүдэд >50K орлогын хувь ялгаатай мэт харагдана.

Баталгаажуулалтын гогцоо: олдворыг нас, боловсрол, ажилласан цаг, occupation-оор давхар задлан тайлбарлана. Таамаглал: боловсролын түвшин ба долоо хоногийн ажлын цаг өндөр байх нь >50K ангилалтай холбоотой. Chi-square, logistic regression, confidence interval, confounder шалгалтаар тестэлнэ.

Мэдлэг үүсгэх гогцоо: холбоо нь шалтгаан гэдгийг шууд хэлэхгүй; өгөгдлийн түүвэр, missing “?” утга, ангиллын хазайлтыг тодорхой бичнэ. Хөдөлмөрийн зах зээлийн мэргэжилтэнтэй үр дүнг review хийж, сургалт/ажлын байрны бодлогын сегментчилэлд зөвхөн шударга, тайлбарлагдах байдлаар ашиглана.

Даалгавар 4 — Adult dataset-ийн хайгуулын жишээ





5. Дүгнэлт ба хавсралт

Гол дүгнэлт: графикийн төрөл, масштаб, өнгө, тайлбар нь өгөгдлийн утгыг дамжуулах чанарт шууд нөлөөлдөг. Weather-ийн хугацаа, улирал, тархалтыг өөр өөр графикаар ялган үзүүлэх нь илүү уншигдахуйц болсон.

Хавсаргасан материал: create_report.py код, weather_three_plots.png, retail_bad_good.png, retail_category_sales.png, adult_exploration.png, мөн эх CSV файлууд.

Дахин ажиллуулах: /opt/anaconda3/bin/python create_report.py. Үүсэх PDF нь 12 pt орчим үндсэн тексттэй, 15 хуудасны хязгаарт багтсан тайлангийн загвар юм.